Deep Learning — Praktikum Sesi 10

Tujuan Praktikum

Mahasiswa mampu mengimplementasikan mekanisme attention dan blok transformer sederhana, memverifikasi kebenaran implementasinya melalui perhitungan manual, serta menunjukkan pemahaman terhadap shape dan jumlah parameter pada setiap tahap.

Instruksi

1. **Verifikasi perhitungan manual (wajib).** Implementasikan scaled dot-product attention untuk satu contoh kecil, lalu bandingkan keluaran program dengan hasil perhitungan tangan. Gunakan q = [1, 0, 1, 0], k1 = [1, 0, 0, 0], k2 = [0, 1, 0, 0], v1 = [1, 0], dan v2 = [0, 1].
2. **Multi-head attention.** Kembangkan modul tersebut menjadi multi-head attention dengan d_model = 8 dan h = 2, kemudian laporkan jumlah parameter hasil perhitungan tangan dan jumlah parameter dari program.
3. **Masking.** Terapkan padding mask dan causal mask, lalu tunjukkan bukti bahwa bobot pada posisi terlarang bernilai nol.
4. **Positional encoding.** Tambahkan positional encoding sinusoidal, lalu jelaskan mengapa langkah ini diperlukan.
5. **Blok transformer.** Susun blok sederhana berisi multi-head attention, feed-forward, residual connection, dan layer normalization.
6. **Uji fungsional.** Latih model kecil pada salah satu tugas berikut, lalu laporkan hasilnya:
   - klasifikasi sekuens pendek menjadi dua kelas, atau
   - prediksi token berikutnya pada data sintetis sederhana.
7. **Verifikasi implementasi.** Lampirkan hasil pemeriksaan shape pada setiap tahap, pemeriksaan jumlah baris matriks perhatian setelah softmax, dan bukti bahwa satu batch kecil dapat di-overfit.

Pertanyaan Analisis

1. Tuliskan shape tensor untuk input, query, key, value, matriks skor, dan keluaran akhir pada konfigurasi d_model = 8, h = 2, T = 4, dan B = 2.
2. Jelaskan mengapa skor attention dibagi dengan akar dari dimensi key, dan sebutkan apa yang terjadi pada softmax jika pembagian tersebut dihilangkan.
3. Jelaskan perbedaan fungsi padding mask dan causal mask, serta akibat yang timbul jika causal mask tidak diterapkan pada model autoregresif.
4. Jelaskan mengapa positional encoding diperlukan, dan bandingkan pendekatan sinusoidal dengan embedding posisi yang dipelajari.
5. Jelaskan mengapa layer normalization lebih sesuai daripada batch normalization pada blok transformer untuk data sekuens.
6. Sebutkan satu kesalahan implementasi yang Anda temukan dan jelaskan cara Anda memverifikasi perbaikannya.
7. (Kaitan linimasa evolusi) Jelaskan satu masalah pada era model recurrent yang diselesaikan oleh attention, dan tunjukkan komponen pada modul yang Anda implementasikan yang menjawab masalah tersebut.
8. (Kaitan linimasa evolusi) Jelaskan perbedaan konsekuensi antara causal mask dan attention dua arah pada keluarga arsitektur yang berbeda, lalu sebutkan dua komponen yang tetap bertahan sejak arsitektur transformer tahun 2017.
9. (Pengayaan NON-RPS) Pilih satu varian efisiensi atau representasi posisi modern, misalnya attention hemat memori atau rotary position embedding, lalu jelaskan secara singkat perbaikan apa yang ditawarkan dibandingkan komponen dasar yang Anda implementasikan. Bagian ini bersifat pengayaan dan tidak dinilai sebagai kompetensi inti.

> Catatan cakupan: linimasa evolusi attention dan transformer pada pertanyaan 7 sampai 9 disajikan sebagai pengayaan NON-RPS untuk memberi konteks mengapa setiap komponen ada. Kompetensi yang dinilai tetap mengacu pada Sub-CPMK Sesi 10, yaitu menerapkan mekanisme attention dan blok transformer sederhana. Prinsip foundation model, pelatihan pendahuluan, dan strategi adaptasi dibahas pada Sesi 11 dan Sesi 12 sehingga tidak diujikan di sini.

Artefak yang Dikumpulkan

- Notebook atau source code yang dapat dijalankan untuk attention, multi-head attention, positional encoding, dan blok transformer.
- Skrip verifikasi yang membandingkan hasil program dengan perhitungan manual.
- Tabel shape dan jumlah parameter setiap komponen.
- Bukti pengujian mask, bukti overfit satu batch, dan hasil latihan model kecil.
- Jawaban Pertanyaan Analisis.